

Lead Article

우리나라 소비자물가상승률 예측

강규호* · 김정성** · 신세림***

우리나라 소비자물가상승률에 대한 예측은 한국은행의 물가안정목표제 운용, 채권시장 참가자의 만기 포트폴리오 최적화, 부동산 시장 및 민간의 소비와 투자 등 경제 전반에 지대한 영향을 미친다. 본 연구는 향후 3년간 우리나라 소비자물가상승률 예측결과를 제시한다. 이를 위해 우선 자기회귀시차(Autoregressive Distributed Lag, ADL) 모형, AR 모형, 소규모 벡터자기회귀(VAR) 모형, 대규모 VAR 모형의 표본외 예측력을 기준으로 모형선택을 실시한다. 물가상승률에는 다수의 잠재적인 예측변수가 존재하기 때문에 12개의 거시변수를 대상으로 ADL 모형에 베이지안 변수선택기법을 도입하고, 예측력 향상을 위한 정밀한 튜닝과정을 고안하고 적용하였다. VAR 모형에는 미네소타 사전분포를 설정하여 차원의 저주 문제를 극복하고자 하였다. 최근 5년을 대상으로 한 장단기 표본외 예측결과, ADL 모형이 점예측과 분포예측 모두에서 여타 경쟁모형에 비해 전반적으로 우월하였다. 예측조합을 통한 예측결과, 우리나라 소비자물가상승률이 2022년 하반기까지는 현재 비슷한 2% 내외의 수준을 유지할 것으로 보이며, 2023년 상반기부터는 1% 내외로 하락할 것으로 전망된다. 80% 신용구간은 예측치의 대략 $\pm 1\%$ p이다.

JEL Classification: G12, C11, E43

핵심 주제어: 표본외 예측, 물가안정목표제, 경기변동, 변수선택

* 제1저자 겸 교신저자, 고려대학교 경제학과 교수 (E-mail: kyuho@korea.ac.kr, Tel: 02-3290-5132)

** 참여저자, 한국은행 조사국 차장 (E-mail: jskim77@bok.or.kr, Tel: 02-759-4114)

*** 참여저자, 고려대학교 경제학과 학부생 (E-mail: shinserim2@korea.ac.kr, Tel: 02-3290-2200)

본 연구내용은 집필자들의 개인의견이며 한국은행의 공식견해와는 무관합니다. 본고의 소비자물가상승률 예측결과는 저자의 개인 홈페이지(<https://faculty.korea.ac.kr/kufaculty/kyuho/index.do>)에 주기적으로 업데이트되어 공표될 예정입니다. 본 연구는 고려대학교 교내연구비(K2001811) 지원을 받아 작성되었습니다.

I. 서론

일반적인 상품 및 서비스가격을 의미하는 물가는 경제주체의 의사결정에 큰 영향을 미칠 뿐만 아니라 경제 내 여타 변수들과 밀접히 연관되어 있는 거시변수이다. 특히, 인플레이션과 실업률 간의 관계가 필립스 커브로 정형화된 이후, 물가와 실물변수 간에 높은 연관성이 있다는 믿음이 널리 확산되었으며, 이와 관련한 실증적 연구들을 바탕으로 주요 선진국들은 물가안정목표제를 통화정책 운영체제로서 받아들이게 된다. 물가안정목표제를 채택한 국가와 이와 비슷한 정책을 운용하는 미국, 유로지역¹⁾은 물가안정목표를 제시하고 향후 물가 경로에 대한 전망치를 정기적으로 공표한다(Table 1 참조). 물가전망 공표는 목표치와 미래 물가 경로 간의 괴리가 발생할 경우 향후 정책방향과 실물변수 변화에 대한 민간의 기대형성을 통해 실제 물가가 목표치에 점차 근접할 수 있다는 인식에 근거한다.

물가의 향후 경로에 대한 이해는 통화정책 관점에서뿐만 아니라 경제활동과 관련한 불확실성이 높아지는 시기에 더욱 중요해질 수 있다. 2020년 코로나19 감염병 위기로 인해 세계경제는 큰 불황에 직면한 바 있다. 그러나 다양한 정책적 대응으로 인해 2021년에는 경기회복세가 확인해지고 향후 물가 경로에 대한 관심도 크게 높아진 상황이다. 물가상승률을 보면 2020년 디플레이션을 우려할 정도로 물가가 낮은 흐름세를 보인 반면 2021년에는 물가목표치인 2%를 넘어서는 물가상승률이 나타나고 있으며, 우리나라를 포함한 주요국에서는 이러한 물

〈Table 1〉 Monetary Policy Scheme of Major Countries

	inflation targeting	monetary targeting	exchange rate targeting	others
major countries	Korea, UK, Japan, etc	China, Argentina, etc	Hong Kong, Singapore, etc	US, Euro area, etc
# of countries	41	26	80	45 ¹⁾

source: IMF AREAER(2019)

1) 학계에서는 미국, 유로지역 등과 같이 물가안정목표제와 유사하게 통화정책을 운영하고 있지만 일부 요건을 충족 못하는 국가는 잠재적(또는 부분적) 물가안정목표제 운영국으로 분류한다. (Roger and Stone (2005), Little and Romano (2009) 등)

가의 높은 오름세가 과연 향후에도 지속될지 여부에 대한 논쟁이 이어지고 있다. 가령, 미국에서는 중앙은행인 연준이 물가오름세가 일시적인 현상이라고 언급하고 있는 반면, 일부 최근 연구는 막대한 재정지출 규모가 경기과열 및 기대변화를 통해 높은 인플레이션이 나타날 수 있다고 우려한다.²⁾(Blanchard, 2021; Summers, 2021 등)

우리나라에서도 2021년 막대한 재정지출로 인해 경기가 회복될 수 있지만 물가상승 압력이 크게 높아질 수 있다는 주장이 지속적으로 제기되고 있다.³⁾ 높은 물가상승이 일시적인 현상에 그칠 경우와 지속적으로 이어질 경우의 민간 행태 변화는 큰 차이가 날 수밖에 없고, 정부와 중앙은행의 대응방식도 달라질 것이다. 이상 언급한 바와 같이 본고의 물가상승률 예측에 대한 논의는 이론적 관점에서 그 함의를 찾을 수 있으며, 미래 물가상승률에 대한 불확실성이 높은 지금과 같은 시기에서는 더욱 시의적절한 작업일 수 있을 것이다.

본 연구는 총 네 개 범주의 물가상승률 예측모형을 설정한 다음, 표본 외 예측력을 비교한다. 모형별 표본외 점예측과 분포예측력 비교를 통해 최적 예측모형을 선택하여 실제 물가상승률 예측을 실시한다. 첫 번째 모형은 자기회귀시차분포(Autoregressive Distributed Lag, ADL) 모형이다. 물가상승률의 시차뿐만 아니라 이론적으로 또는 직관적으로 물가상승률과 관련이 높은 11개 거시변수의 시차변수가 예측변수로 사용된다. 물가상승률은 여타 거시변수들과 함께 일반균형하에서 동시에 또는 동태적으로 결정된다. 기본적으로 각 거시변수들은 모든 자기상관이 있는 구조충격의 함수이기 때문에 거시변수들 간에 동태적 상관관계가 존재한다. 따라서 각 거시변수는 여타 거시변수 예측에 있어 정보변수의 역할을 할 수 있다. 하지만 거시변수들이 이론적으로 밀접한 (시차)관계를 가진다고 해서 특정 거시변수에 대한 각 거시변수의 예측력이 통계적으로 유의하다는 것을 의미하지는 않는다. 특정 소수의 설명변수를 연구자가 선형적으로 선택하는 방법도 있지만, 이론적으로 중요한 변수가 통계적으로는 예측력 향상과 관련이 적을 수 있고 정작 중요한 변수가 누락되었을 가능성이 존재한다. 그렇다고 해서 이론에 기반하여 잠재적으로 중요한 변수를 모두 넣게 되면 일부 통계적으로 불필요한 변수들로 인해 발생하는 과도적합(overfitting) 문제가 발생한다.

2) 가령, Summers는 2009년 글로벌 금융위기 당시 재정지출 규모가 GDP갭의 절반 정도 수준이었으나 급변 부양책의 경우 GDP갭의 3배를 초과하는 규모라고 평가하면서 인플레이션 위험이 높다고 지적하였다

3) “우리나라도 재정발 인플레이션 올까”(한겨레, 2021.6.10.일), “추경 등 인플레 압력”(전자신문, 2021.6.10.일)

이러한 문제를 완화하기 위해서 베이지안 접근법에서 널리 사용되는 Spike-and-Slab 사전분포를 이용한 베이지안 변수선택기법을 도입한다⁴⁾. 일반적으로 모든 설명변수의 예측력이 강한 것이 아니기 때문에 변수선택기법 도입을 통해 예측력이 낮은 설명변수를 회귀식에서 제외함으로써 중요한 변수의 통계적 유의성과 예측력을 높일 수 있다. 결과적으로 변수선택기법을 통해 과도적합 문제와 변수누락 문제를 동시에 해결하면서 예측력 극대화를 도모할 수 있다. 특히, 예측시계(forecast horizon) 별로 선택되는 변수와 예측 정확도는 표본내 기간(in-sample period), 사전분포를 구성하는 하이퍼-파라미터(hyper-parameter)에 따라서 예민하게 달라지는 경우가 많기 때문에, 예측시계 별로 광범위하고 정밀한 튜닝(tuning) 과정을 고안하여 적용한다.

두 번째로 고려되는 모형은 ADL 모형의 특정 경우에 해당하는 자기회귀(Autoregressive, AR) 모형이다. AR 모형은 ADL 모형에 비해 훨씬 단순하기 때문에 본고는 AR 모형을 기준(benchmark) 예측모형으로 간주한다.

장기 예측은 예측변수의 예측 여부에 따라 직접 예측(direct forecasting)과 반복 예측(iterated forecasting)으로 구분된다. 반복 예측은 H(=2,3,...)-기 예측 시 모든 변수에 대한 1-기 예측모형을 설정하고, (H-1)-기 예측치를 시차 설명변수로 사용하는 방식이다. 반면, 직접 예측은 현재 종속변수를 H-기 시차변수에 회귀한 다음, 모수 추정치와 현재 예측변수의 값으로 H-기 이후 종속변수 예측치를 산출하는 방식이다. ADL과 AR 모형은 직접 예측을 통해 물가상승률을 예측한다. 직접 예측의 대안인 반복 예측을 위해서는 물가상승률뿐만 아니라 다른 거시변수들의 예측치도 산출해야 하므로 VAR 모형을 고려 대상 모형에 포함한다. 본고는 총 두 종류의 VAR 모형을 설정하였는데, 하나는 12개 거시변수 모두가 고려되는 대규모(large-scale) 벡터자기회귀(LS-VAR) 모형이고 나머지 하나는 물가상승률을 포함해서 5개 거시변수만을 고려한 소규모(small-scale) 벡터자기회귀(SS-VAR) 모형이다. VAR 모형을 이용한 예측에 일반적으로 발생하는 차원 저주 문제를 최소화할 수 있도록 미네소타(Minnesota) 사전 분포를 설정한다. 결과적으로 본 연구에서 고려되는 예측모형은 ADL, AR, LS-VAR, SS-VAR 모형이다.

분석에 사용된 자료는 2003년 1분기부터 2021년 2분기까지의 물가상승률 및 실물경기와 유동성, 해외요인 등을 고려한 11개 거시변수이다. 최근 5년을 대상으로 한 장단기 표본외 예측결과, 점예측과 분포예측 모두에서 ADL 모형이 여

4) 본고는 시차를 3분기까지 고려하기 때문에 설명변수가 상수항을 포함하여 총 37개에 이른다.

타 경쟁모형에 비해 전반적으로 우월하였다. 예측조합을 통한 예측결과, 물가상승률이 2022년 하반기까지는 현재 비슷한 2% 내외의 수준을 유지할 것으로 보이며, 2023년 상반기부터는 1% 내외로 하락할 것으로 예측된다. 경제주체의 의사결정에 있어 물가상승률 예측치뿐만 아니라 불확실성의 크기도 대단히 중요한데, 본 연구의 분포예측결과에 의하면 80% 신용구간은 예측치의 대략 $\pm 1\%$ 이다. 연구결과의 강건성을 확인하고 활용성을 확대하고자 본고의 물가상승률 예측결과는 온라인(<https://faculty.korea.ac.kr/kufaculty/kyuho/index.do>)에 주기적으로 업데이트되어 공표될 예정이다.

튜닝과 물가상승률 예측결과로부터 세 가지 주목할 만한 점들이 발견되었다. 첫째, 예측시계 별로 선택되는 중요 예측변수가 크게 상이하였다. 예를 들어, 단기 예측에는 전기 물가상승률과 더불어 국내 실물경기변수의 예측력이 강한 반면, 장기 예측에는 미국 물가상승률, 통화량, 인플레이션 기대 등이 주요 정보변수로 작용하였다. 둘째, SS-VAR와 LS-VAR 모형은 단기 점예측에 유용한 반면, 장기 점예측과 분포예측에는 ADL이나 AR 모형을 이용한 직접 예측이 VAR 모형을 통한 반복 예측보다 크게 우월하였다. 이는 VAR 모형에 내재한 차원의 저주 문제가 예측시계가 커질수록 심각해지기 때문이라고 해석할 수도 있다. 또한 다른 한편으로는 장기 예측에 있어 불필요한 예측변수의 영향력을 0으로 제약하는 Sparsity가 0으로 근접하게 하는 Shrinkage보다 유용하다는 것을 의미한다. 마지막으로, 모형추정에 사용되는 표본의 크기에 있어 첫 기부터 예측시점이 경과하면서 표본내 크기(in-sample size)가 함께 커지는 확장(Expanding) 회귀보다 표본내 크기를 일정한 값에 고정한 채 예측대상시점과 표본내 기간을 동시에 하나씩 이동시키는 롤링(Rolling) 회귀가 훨씬 더 정확한 표본외 예측력을 보여줬다. 이는 롤링 회귀가 2012년 전후 우리나라 평균 물가상승률의 하락을 반영하기 때문인 것으로 보인다. 물론 확장 회귀로 예측하더라도 평균 물가상승률의 하락을 반영하는 설명변수가 존재하여 장기적 추세를 잡아줄 수 있다면 확장 회귀의 결과가 더 나을 수도 있다. 그러나 롤링 회귀의 표본외 예측력이 높은 것으로 봐서 본고가 고려한 11개 거시변수 중에서 그러한 역할을 담당하는 예측변수는 없는 것으로 판단된다.

기존 문헌들에 의하면 기본적으로 물가상승률 예측에 있어 널리 사용되는 표준화된 단일 모형이 존재하지는 않는다. 대신 다양한 모형으로부터 예측치를 산출한 다음, 일정한 가중치로 예측조합을 하는 방식으로 물가상승률을 예측해왔

다. 예를 들어, Wright (2009)은 모형별 사후확률을 가중평균으로 사용하는 베이 지안 모형평균법(bayesian model averaging)이 단순등가중치모형평균법(simple equal weighted model averaging)보다 더 높은 예측력을 가짐을 보였으며, 최근 연구인 Fulton, Chad, and Kirstin Hubrich (2021)는 AR, ADL, 필립스 커브 모형, VAR 모형으로 최대 2년 이후의 미국 인플레이션을 예측하였다. 모형별 예측결과를 RMSE를 기준으로 비교하였는데, 예측조합의 예측력이 단일 모형보다 높으며, 직접 예측보다 반복 예측 모형의 예측력이 높고, 주관적 예측은 단기에 높은 예측력을 가짐을 보였다.

우리나라 물가상승률 예측 관련 최근 연구로는 최인·황승진(2012)과 김현학(2015)가 있다. 최인·황승진(2012)은 Stock and Watson (1999)의 주성분 분석을 이용한 차원축소 방법론을 활용하여 2000년 11월부터 2009년 9월까지의 154개월별 거시금융 자료로 2009년 10월부터 2011년 6월까지 물가상승률을 예측하였다. 사용된 모형은 AR 모형과 여러 ADL 모형이다. 예측시계는 최대 6개월이며, 점예측을 실시하였다. 표본외 예측결과, 실업률 또는 이자율 차이와 주성분이 예측변수인 ADL 모형이 가장 정확한 점예측치를 산출하였다. 한편 김현학(2015)도 월별자료를 사용하여 물가상승률을 예측하였는데, 표본기간은 1970년 1월 이후이며 표본외 예측기간은 2000년 1월부터 2013년 12월까지이다. 예측시계는 최인·황승진(2012)와 마찬가지로 최대 6개월이다. AR 모형과 더불어 주성분 분석과 LASSO, Ridge 회귀분석 등 다양한 차원축소 방법을 채택하였다. 표본외 예측결과, 개별 모형 중에서는 AR 모형이 가장 좋은 점 예측성결과를 보여주었다. 또한 각 모형별 로그 스코어(score)를 기반으로 예측조합을 실시하면 예측력이 다소 향상된다는 것을 보고하였으며, 비모수적 부트스트랩을 이용해서 분포 예측을 실시하였다.⁵⁾

위 두 선행연구는 연구주제와 예측에 AR과 ADL 모형을 사용하고 차원축소방법을 적용한다는 점이 공통적이다. 그럼에도 불구하고 본 연구는 여러 방면에서 기존 연구와 차별화된다. 첫째, 위 두 선행연구가 월별자료를 사용하여 단기예측에 초점을 맞춘 반면, 본 연구는 분기별 자료를 통해 단기와 장기 예측 모두를 시도한다. 둘째, 방법론 상으로 본 연구는 베이지안 접근법을 채택하여 점예측치뿐만 아니라 분포예측결과를 제시한다. 또한 차원축소 측면에서 본고는 주성분 분석 대신 Ridge와 유사한 베이지안 변수선택기법을 도입한다. 그 이유는 기

5) 다만 김현학(2015)는 분포예측력에 대한 평가는 실시하지 않았지만, 표본외 예측결과로부터 분포예측치가 물가의 방향성 변화에 대한 정보를 제공할 수 있음을 시사하였다.

본적으로 주성분은 변수 간의 공통적인 움직임을 잡아내는데, 본고가 고려하는 변수들은 각 변수가 속한 카테고리가 상이하여 중복된 정보가 많지 않아서 유의한 주성분의 존재 자체가 강하지 않기 때문이다. 그와 함께 김현학(2015)의 연구에서 주성분 분석의 유용성이 강하지 않다고 보고된 점과 주성분을 사용하면 해석이 불가능하다는 점도 고려하였다. 다음으로, 선행연구와 달리 본 연구는 반복예측을 통한 VAR 모형의 표본외 예측정확도도 검증하였다. 마지막으로 본 연구는 차원축소를 통한 예측력 향상에 주요한 튜닝과정을 우리나라 물가상승률 예측에 적합하도록 고안하였다는 점과 예측결과를 주기적으로 업데이트하여 온라인에 지속적으로 공개한다는 부분도 선행연구와 구별된다.

본 연구의 주요한 학술적 기여는 두 가지이다. 하나는 본 연구가 우리나라 장단기 물가상승률의 분포예측결과를 제시하고 이를 주기적으로 공표하는 첫 연구 성과라는 점이다. 분포예측 결과로부터 점 예측치와 더불어 구간 예측치를 계산할 수 있으므로 물가상승률의 불확실성과 실현 가능한 물가상승률의 범위를 추론할 수 있다. 또한 분포예측 결과로부터 향후 1년 또는 2년 뒤 물가상승률이 물가안정목표제를 달성할 확률을 수치화할 수 있다는 장점도 있다. 본 연구는 측단기 물가상승률 예측치와 불확실성 측정치를 제공함으로써 중앙은행과 장기채권시장 참가자의 효율적인 의사결정에 상당한 도움을 줄 것으로 기대한다. 두 번째 학술적 기여는 예측력 향상에 결정적인 엄밀한 효과적인 튜닝과정을 고안한 것이다. 본 연구가 고려하는 예측모형들과 Spike-and-Slab 베이지안 변수선택 알고리즘 자체는 Korobilis (2013), 강규호(2018), 김현학(2015), Yang, Xiang and Shu (2018), Kim and Lee (2020) 등 이미 기존의 여러 연구에서 널리 사용되어 왔기 때문에 전혀 새롭지 않다⁶⁾. 하지만 예측력 향상을 위해서는 사용되는 모형의 종류도 중요하지만 그 모형을 적용하는 방식도 대단히 중요하다. 특히 Spike-and-Slab 베이지안 변수선택기법은 종속변수에 적합한 튜닝 파라미터를 설정해야 하는데, 본 연구는 우리나라 물가상승률 예측을 위한 정밀하고 광범위한 튜닝과정을 제안하고, 이를 적용하면 실제로 모형의 예측력을 크게 개선할 수 있음을 보인다.

본고는 다음과 같이 구성된다. 2장은 각 예측모형의 설정과 추정, 표본외 예측 및 튜닝과정을 구체적으로 설명한다. 3장은 표본외 예측결과와 예측력에 기반한 모형선택결과, 선택된 모형으로부터 생성된 물가상승률 사후 예측분포 결과를

6) 강규호(2018)는 조건부 베이지안 예측분포 조합에 기반한 베이지안 머신러닝을 사용하여 주택담보대출을 예측하였다.

제시한다. 4장에서는 연구결과를 요약하고 이로부터 정책적 시사점을 도출한 다음, 본 연구의 한계와 추가 연구방향을 논의한다.

II. 계량분석

이 장에서는 본 연구에서 고려되는 예측모형들을 소개하고, 각 모형별 추정 및 예측분포 생성과정, 표본외 예측과 튜닝, 예측력 평가기준에 대해서 설명한다.

1. 예측모형 설정

가. h -기 예측 ADL 모형

서론에서 언급한 바와 같이 본 연구에서는 네 개의 개별 예측모형을 설정하고 각 모형별 표본외 예측력 비교를 통해 모형선택 또는 조합을 실시한다. 첫 번째 모형은 Stock and Watson (1999), Chad, and Kirstin Hubrich (2021), 최인·황승진 (2012)과 강규호(2018)의 연구에서 물가상승률 또는 가계부채증가율 예측에 사용된 ADL 모형이다. 이 예측모형은 종속변수의 자기회귀항에 시차가 반영된 강외생적인 예측변수의 항이 추가된 모형이다. y_t 는 t 시점의 전년동기대비 소비자물가증가율이다. h -기 예측을 위한 ADL 모형하에서 y_t 의 조건부 평균이 아래와 같이 h 기 또는 그 이전의 자기시차 또는 외생변수에 의해서 설명된다고 가정한다.

$$y_t = \beta_0 + \sum_{j=1}^J \rho_j y_{t-j-h+1} + \sum_{k=1}^K \sum_{j=1}^J \phi_{k,j} z_{k,t-j-h+1} + e_t \quad (1)$$

오차항 $e_t \mid \sigma^2 \sim N(0, \sigma^2)$ 는 베이지안 추정방법상 편의를 위해 조건부 정규분포를 따르며, $\sigma^2 \sim IG(\alpha_0/2, \delta_0/2)$ 은 켈레분포인 역감마분포를 따른다고 가정한다. $z_{k,t}$ 는 t 시점의 $k(=1, 2, \dots, K)$ 번째 예측변수를 나타내며, J 는 고려되는 최대 시차의 크기이다. 따라서 위 식에서 고려되는 설명변수는 상수항을 포함하여 총 $((K+1) \times J + 1)$ 개이다. 예를 들어, $K=11$ 이고 $J=3$ 이면 설명변수의 수가 무려 37개가 된다. 특히 최근 14년간의 분기별 자료를 사용하여 추정하는 상황에서 이렇게 예측변수의 수가 너무 클 경우, 중요하지 않은 예측변수를 포함할 가

능성이 높아지고 모형의 예측력이 크게 저하될 수 있다. 본고에서는 서론에서 언급한 바와 같이 과도적합 문제 극복을 위해 Spike-and-Slab 베이지안 변수선택기법을 도입하여 예측력이 높은 변수와 시차 조합을 선별하여 예측에 사용하고자 한다.

중요한 예측변수의 계수는 0과 먼 값을 갖고, 중요하지 않은 예측변수의 계수는 0에 가까울 것이라는 아이디어에 착안하여 베이지안 변수선택 모형은 예측변수 계수를 평균을 0으로 하고, 분산이 큰 정규분포와 0에 매우 가까운 정규분포의 혼합으로 가정한다. 이러한 사전분포는 실제 계수가 중요하지 않은 경우 임의로 계수값을 0에 극도로 가깝게 하고, 중요한 경우(즉 실제 계수가 0과 크게 다른 경우), 자료의 정보에 의해 추정되도록 하는 역할을 한다. 각 설명변수의 선택 여부를 결정하는 지시변수에 대한 사후분포도 도출이 되며, 지시변수의 사후평균을 각 설명변수의 중요도라고 칭한다. 각 예측변수의 중요도는 0과 1사이의 연속적인 값으로 나타내는데, 1에 가까울수록 예측력이 높고 깁스 샘플링 반복시행 중에서 그 예측변수가 사후예측분포 생성에 사용되는 빈도가 높다는 것을 의미한다.

추정과정 설명의 편의를 위해 식 (1)을 다음과 같이 단순화하여 나타낸다.

$$y_t = \beta_0 + \sum_{k=1}^{K+1} \sum_{j=1}^J \beta_{k,j} x_{k,t-j-h+1} + e_t \quad (2)$$

그런 다음, 위 식을 다시 아래와 같은 행렬식으로 표현할 수 있다.

$$Y = X\beta + e$$

여기서 Y 는 물가상승률의 시계열벡터이고 X 는 자기회귀항과 여타 거시변수의 시차로 이루어진 설명변수 행렬이다. $\beta = (\beta_0, \beta_{1,1}, \beta_{1,2}, \dots, \beta_{K+1,J-1}, \beta_{K+1,J})'$ 는 각 예측변수의 계수벡터이다. $\beta_{k,j}$ 에 대한 Spike-and-Slab 조건부 사전분포는 다음과 같이 주어진다.

$$\begin{aligned} \beta_{k,j} &| \gamma_{k,j} b_0, b_1 \sim N(0, b_{k,j}) \text{ for } k=1, 2, \dots, K+1 \\ b_{k,j} &= \gamma_{k,j} \times b_1 + (1 - \gamma_{k,j}) \times b_0 \end{aligned} \quad (3)$$

$\gamma_{k,j}$ 는 (k,j) 번째 예측변수가 예측에 있어 중요한지에 따라 0 또는 1의 값을 가지는 지시변수이다. 만일 해당 변수가 중요하다면 (즉, $\gamma_{k,j} = 1$), $\beta_{k,j}$ 는 0에서

멀리 떨어진 값일 확률이 클 것이므로 $\beta_{k,j}$ 의 분산 $b_{k,j}$ 는 충분히 큰 값을 가진다. 반대로 (k,j) 번째 예측변수가 중요하지 않다면 (즉, $\gamma_{k,j} = 0$), $\beta_{k,j}$ 는 0과 가까운 값일 것이므로 $b_{k,j}$ 는 0과 가까운 작은 값을 가진다. $\gamma_{k,j}$ 의 사전분포는 $\gamma_{k,j} = 1$ 일 확률이 p 인 베르누이 분포이다. 또한, 변수선택과정에서 데이터로부터 최대한 많은 정보를 모형에 반영하고자 계층적 모형을 가정하여 p 와 b_0 , b_1 에 대해서도 사전분포를 설정하였다. p 는 0과 1사이의 확률을 나타내는 연속된 값이므로 베타분포 $p \sim \text{beta}(a_0, c_0)$ 를 따르며, b_0 와 b_1 은 다음과 같은 역감마분포를 가정하였다.

$$b_0 \sim IG\left(\frac{\alpha_{00}}{2}, \frac{\delta_{00}}{2}\right)$$

$$b_1 \sim IG\left(\frac{\alpha_{01}}{2}, \frac{\delta_{01}}{2}\right)$$

이 때, 역감마분포의 평균은 $0.5\delta_{00}/(0.5\alpha_{00} - 1)$ 이므로 δ_{00}/α_{00} 이 0에 가깝도록 하이퍼-파라미터인 δ_{00} 와 α_{00} 의 값을 설정한다. 반면 δ_{01} 와 α_{01} 은 $0.5\delta_{01}/(0.5\alpha_{01} - 1)$ 을 충분히 크게 하여 사전정보가 비정보적(uninformative)이 되도록 한다. 이 때문에 b_0 를 Spike 분산이라고 하고, b_1 를 Slab 분산이라고 한다.

나. h -기 예측 AR 모형

두 번째 경쟁모형은 아래와 같은 AR 모형이다.

$$y_t = \beta_0 + \sum_{j=1}^J \rho_j y_{t-j-h+1} \quad (4)$$

AR 모형은 ADL 모형에 특정 제약을 부여한 아주 단순한 모형이므로 ADL 모형과의 예측력 비교를 통해 ADL 모형에 과도적합 문제가 있는지를 검토할 수 있다. 자기회귀모형 역시 예측 시계별로 베이지안 변수선택 과정을 앞서 설명한 ADL모형과 같은 방식으로 실행한다.

다. LS-VAR 모형과 SS-VAR 모형

Y_t 는 t 시점의 거시변수 벡터이다. LS-VAR 모형과 SS-VAR 모형은 Y_t 의 차원

와 구성 외에는 모형 설정상 차이가 없다. 시차가 J 인 VAR 모형은 아래와 같이 주어진다.

$$Y_t = C + \Phi_1 Y_{t-1} + \Phi_2 Y_{t-2} + \dots + \Phi_J Y_{t-J} + N(0, \Omega) \quad (5)$$

여기서 $\beta_{i,k,j}$ 는 Φ_j 의 (i,k) 번째 요소이고, 미네소타 사전분포 하에서 $\beta_{i,k,j}$ 은 사전적으로 아래와 같은 정규분포를 따른다고 가정한다.

$$\beta_{i,k,j} \sim N(c_{i,k,j}, v_{i,k,j})$$

단, $c_{i,k,j} = 0.5$ if $j = 1$ and $i = k$ and 0, otherwise

$$v_{i,k,j} = \frac{\lambda}{j^2} \text{ if } i = k, \text{ and } v_{i,k,j} = \frac{\lambda}{j^2} \tau \frac{\omega_i}{\omega_k}, \text{ otherwise}$$

Giannone and Primiceri (2015)가 제안한 대로 ω_i 는 각 변수를 AR(4)로 추정했을 때 오차항의 표준오차의 최소 자승 추정치이다. ω_i/ω_k 은 두 변수 간 단위나 상대적인 크기(scale)가 상이하어 사전분포가 지나치게 강하거나 약해지는 현상을 방지하도록 설명변수의 단위를 조정하는 역할을 한다. 미네소타 사전분포는 기본적으로 사전 분산은 시차(j)가 클수록 작아지며, 자기회귀항이 아닌 항에 대해서도 0과 1사이의 값을 가지는 τ 를 곱하여 분산을 축소한다. 마지막으로 예측결과가 하이퍼-파라미터 설정에 민감하지 않도록 계층적(hierachical) 사전분포를 상정하여 (λ, τ) 는 사전분포가 역감마분포인 모수이고 사후 예측과정에서 이 모수들에 대한 사후분포가 샘플링되도록 한다.

$$\lambda \sim IG(a_\lambda/2, b_\lambda/2) \text{ and } \tau \sim IG(a_\tau/2, b_\tau/2)$$

마지막으로 Ω 의 사전분포는 켈레 분포인 역위샷(Inverse-Wishart) 분포, $IW(R_0, \nu_0)$ 이다.

2. 추정방법

ADL 모형의 사후분포 추정과정은 <부록 A>에 설명하였으며, AR 모형은 ADL 모형 추정 알고리즘을 단순화하여 적용하면 추정할 수 있다. 미네소타 사전분포가 부여된 VAR 모형의 추정 과정은 Dieppe, Legrand, and Roye (2016)을

참조하길 바란다.

다음으로 물가상승률의 사후예측분포는 해석적으로 도출되지 않으므로 모수의 사후분포를 이용하여 수치적 적분법을 이용하여 근사할 수 있다. 예를 들어, ADL 모형의 경우 h 기 이후 물가상승률은 각 깁스 샘플링 반복시행마다 모든 모형 모수의 사후 샘플이 주어지면 아래와 같은 조건부 정규분포에서 생성된다.

$$y_{t+h} \sim N(\beta_0 + \sum_{k=1}^{K+1} \sum_{j=1}^J \beta_{k,j} x_{k,t-j+1}, \sigma^2)$$

3. 표본외 예측

추정에 사용하는 시계열자료는 2003년 1분기부터 2021년 2분기까지이고, 이 중 최근 5년 기간(2016년 3분기-2021년 2분기)을 대상으로 예측시계별 각 모형의 표본외 예측력을 평가한다.⁷⁾ 예를 들어, 3분기 이후(3-quater-ahead) 예측의 경우, 2015년 4분기까지의 자료를 이용하여 2016년 3분기 물가상승률을 예측하고, 2016년 1분기까지의 자료를 이용하여 2016년 4분기의 물가상승률을 예측한다. 이런 방식으로 2021년 2분기까지 총 20번의 표본외 예측을 실시한다. 예측시계에 따라서 사용되는 표본내 기간(in-sample period)만 달라지고 예측대상인 표본외 기간은 최근 5년으로 동일하다.

모형의 예측력을 판단하는 방법으로는 로그 사후예측우도(posterior predictive likelihood, PPL)과 RMSE(root mean squared errors)를 사용한다. 로그 PPL은 분포예측의 정확도를 측정하는 방법인데, 각 모형으로부터 도출된 예측분포로부터 실제 물가상승률의 예측밀도를 표본외 기간에 걸쳐 계산하여 곱한 값, 즉 표본외 기간 물가상승률의 조건부 결합예측밀도이다.⁸⁾ RMSE는 예측오차 제곱의 평균에 루트를 취해서 구하며, 기본적으로 점예측력의 평가지표이다. 본 연구에서는 RMSE를 기준으로 세 모형((i) ADL 모형 중 가장 점예측력이 좋은 모형, (ii) ADL 모형 중 두 번째로 점예측력이 좋은 모형, (iii) AR 모형 중 가장 점예측력이 좋은 모형)을 선택한다⁹⁾. 그런 다음, 선택된 두 ADL 모형과 최적 AR 모형의

7) 표본외 기간을 최근 5년으로 설정한 이유는 예측에 필요한 시계열자료를 충분히 확보하면서도 특정 기간에 의존하지 않도록 표본외 기간을 최대한 길게 잡고자 함이다.

8) PPL의 구체적인 계산방법은 강규호(2018)을 참조하길 바란다.

9) 사전분포 또는 자료의 사전처리방식이 다른 ADL 모형은 종속변수와 설명변수가 동일하다고 하더라도 상이한 ADL 모형으로 간주된다.

PPL을 이용하여 각 모형별 가중치를 계산한다. 각 모형에서 생성된 사후예측분포를 모형별 가중치대로 조합함으로써 모형별 모수 불확실성과 모형 불확실성이 함께 반영된 물가상승률의 사후예측분포를 도출한다.

4. 튜닝

예측변수의 수가 많은 ADL 모형에 베이지안 변수선택 알고리즘을 도입하면 하이퍼-파라미터나 표본기간의 설정 등 다양한 모형설정에 따라서 예측정확도가 크게 달라지는 경향이 있다. 특히 (i) Spike 분산(b_0)의 사전분포, (ii) 예측변수의 시차, (iii) 표본내 기간, (iv) 설명변수의 단위조정(rescaling) 방법, (v) 변수집합 필터링이 모형의 예측력에 크게 영향을 미치는 사전 설정값들이다. 본 연구는 이 다섯 종류의 사전설정을 대상으로 표본외 예측력을 극대화하는 사전설정의 조합을 찾는 작업을 진행한다.

가. Spike 분산의 평균

베이지안 변수선택 모형에서 중요하지 않은 변수에 대한 사전분산 b_0 의 평균의 크기에 따라 선택되는 변수가 달라질 수 있다. 만약 b_0 의 값이 너무 작다면 중요하지 않은 변수를 제대로 모형에서 제외하지 못할 수 있으며, b_0 의 평균이 클수록 중요하지 않은 변수에 포함되는 변수의 수가 많아지고 따라서 중요한 변수가 누락될 수 있기 때문이다. b_0 가 너무 크거나 작으면 모형이 예측력이 감소하고, 사전에 적절한 크기의 b_0 가 알려져 있지 않으므로 예측력이 극대화되는 최적의 하이퍼-파라미터를 찾기 위해 본 연구에서는 α_{00} 를 1,000으로 고정하는 대신, b_0 의 사전평균($=\delta_{00}/\alpha_{00}$) 네 가지($10^{-4}, 10^{-6}, 10^{-8}, 10^{-10}$)을 비교하여 최적 사전평균을 탐색한다.

나. 시차

예측변수에 발생한 효과가 물가상승률에 파급되는 시간이 변수별로 상이할 수 있다. 예측변수에 이미 내재된 물가상승률에 대한 정보는 현재 예측변수가 아니라 예측변수의 시차값이 더 많이 포함할 가능성이 있다. 이러한 점을 감안하여 본 연구는 예측변수의 시차를 1분기부터 최대 3분기까지 고려한다.

다. 표본내 기간

표본기간 중 설명변수와 예측변수의 동태성에 구조적인 변화가 있었다면 이는 종속변수와 예측변수 간 상관관계 크기에 영향을 미칠 수 있다. 이러한 잠재적인 구조변화 가능성을 고려하지 않는다면 모수의 사후분포에 편의가 발생하고 결과적으로 모형의 예측력이 크게 저하될 수 있다. 특히 우리나라 소비자물가상승률은 2012년 즈음을 기점으로 한국은행의 물가안정목표치인 2%를 하회하며 이전보다 낮아졌다. 이러한 구조변화의 효과를 고려하고자 확장 회귀분석과 함께 롤링 회귀분석도 적용하여 비교한다. 또한 구조변화 시점이 명확하지 않기 때문에 네 종류의 롤링 윈도우의 크기(20분기, 24분기, 28분기, 32분기)를 각 예측시계별로 표본외 예측에 적용하고 비교한다.

라. 설명변수의 단위조정

기본적으로 베이지안 변수선택에서 변수의 중요도는 계수의 크기에 의해서 결정되며, 예측변수의 단위는 계수의 크기에 직접적인 영향을 주므로 모형의 예측력과도 관련이 깊다. 따라서 각 예측변수 별로 예측력의 향상의 기여도가 적절히 반영될 수 있도록 예측변수의 크기를 조정할 필요가 있다. 변수의 단위조정에는 주로 Z-score 방법과 미네소타 사전분포 형태(Minnesota prior type)이 사용된다. Z-score 방법은 말 그대로 각 변수의 표본평균은 0, 편차는 1이 되도록 표준화하는 방법이다. 미네소타 형태는 VAR 추정에 사용된 미네소타 사전분포에서와 같이 각 변수에 (ω_y/ω_k) 를 곱하여 상대적으로 잡음이 많은 설명변수에는 작은 가중치를 부여하는 방식이다. 단, 자기시차항에 대해서는 단위조정을 진행하지 않았다. 본 연구는 두 단위조정 방식을 모두 표본외 예측에 적용하고 비교한다.

마. 변수집합 필터링

동일한 사전분포와 설명변수 단위조정방법, 표본내 기간 및 시차를 사용하더라도 어떤 변수집합에 이를 적용하나에 따라서 예측결과가 크게 달라진다. 변수집합이 너무 크면 불필요한 변수들로 인해 중요한 변수의 예측력이 비효율적으로 추정되어 예측력이 저하될 수 있다. 또한 상호 간에 상관관계가 높은 설명변수가 다수 포함되어도 유사한 문제가 발생한다. 따라서 가급적 직교적인 정보를 가진 변수들로 예측변수 집합을 구성하여 변수선택을 적용해야 한다. 하지만 실제 통계분석과 정에서는 사전에 효율적인 변수집합을 구성하기가 어렵다. 이러한 문제를 해결하기

위해서 본 연구는 변수집합 필터링을 진행하는 방법을 고안하였다.

변수집합 필터링은 여러 단계에 걸쳐서 변수선택을 진행하는 것인데, 본 연구는 실제 적용과정에서 4단계에 걸친 필터링이 계산 비용은 지나치게 크지 않으면서도 상당한 예측력 개선 효과가 있음을 발견하였다. 1단계에서는 전체 변수집합을 대상으로 변수선택 알고리즘을 적용하고 사후 중요도가 0.1 이하인 변수들을 변수집합에서 제외한다. 2단계에서는 축소된 변수집합에 다시 변수선택을 실시하고 중요도가 0.2 이하인 변수들을 제외한다. 3단계는 기준을 0.3, 4단계는 중요도가 0.4에 미치지 못하는 변수를 제외한다. 다시 말해, 1단계처럼 변수의 수가 아주 많을 때는 중요한 변수가 중요하지 않은 변수로 추정될 가능성이 많기 때문에 기준을 낮게 잡고, 단계를 거듭할수록 기준을 점차 높여가면서 예측력이 낮은 변수를 변수집합에서 제외시켜 나가는 것이다. 변수선택 필터링을 적용하면 중요한 변수도 정확하게 추정될 뿐만 아니라 과도적합 문제가 적어서 중요한 예측변수의 계수도 보다 세밀하게 추정할 수 있어 결국 예측력 향상을 성취할 수 있다.

결과적으로 본 연구는 예측력을 극대화하는 변수선택 알고리즘 구현을 위해서 Spike 분산, 시차, 표본내 크기, 설명변수의 단위조정방법, 변수집합에 대해서 튜닝을 진행하고 최적의 사전설정 조합을 탐색한다. 특히 각 예측시계(=1, 2,..., 12분기) 별로 개별 ADL모형을 총 $4_{(Spike\text{분산})} \times 3_{(시차)} \times 5_{(표본내\ 크기)} \times 2_{(단위조정)} \times 4_{(변수집합)} = 480$ 번 추정하고 최근 20분기의 물가상승률을 대상으로 평균적인 점예측 및 분포예측 정확도를 비교한다. 구체적인 튜닝 알고리즘은 <부록 B>를 참조하길 바란다.

<Table 2> Hyper-parameters This table presents the hyper-parameters for the prediction models

ADL and AR		VAR	
δ_{00}/α_{00}	$10^{-4}, 10^{-6}, 10^{-8}, 10^{-10}$	a_λ	20
α_{00}	1,000	b_λ	3.2
δ_{01}/α_{01}	0.16	a_τ	20
α_{01}	20	b_τ	0.8
α_0	5	R_0	$\nu_0 \times \text{diag}(w_1, w_2, \dots, w_{K+1})$
δ_0	0.1	ν_0	$\text{dim}(Y_t) + 2$
a_0, c_0	5	J	1, 2, ..., 4
J	1, 2, 3	Window size	20, 24, 28, 32
Window size	20, 24, 28, 32		

표본외 예측이 완료되면 우선 RMSE를 기준으로 ADL 중 가장 예측력이 높은 두 모형(즉, 가장 작은 그리고 두 번째로 작은 RMSE를 산출하는 사전설정값의 조합)과 하나의 AR 모형을 선택한다. 그런 다음, PPL을 기준으로 각 모형의 가중치를 계산하고 각 모형으로부터 생성된 예측분포를 가중 조합하여 사후 예측조합(forecast combination)이 도출된다. 예측조합 대상 모형을 세 개로 제한한 이유는 실험결과 4개 이상으로 확대하면 예측분포의 꼬리가 지나치게 커져서 예측의 신뢰성이 저하되는 현상이 발견되었기 때문이다. 이와 동일한 이유로 베이지만 모형 평균(Bayesian model averaging)의 분포예측력이 오히려 가장 좋은 모형 하나만 사용한 경우에 비해 악화되는 현상이 종종 발생한다. 각 모형별 튜닝의 대상인 하이퍼-파라미터와 여타 하이퍼-파라미터의 값들을 Table 2에 나타내었다.

Ⅲ. 추정결과

1. 통계자료

추정에 사용할 자료의 표본기간은 2003년 1월부터 2021년 5월까지의 월별자료이고, 월별자료를 분기 중 평균을 취하여 분기자료로 변환하였다. 인플레이션에 대한 예측치와 불확실성을 월별로 업데이트하고 모니터링하는 등 속보성 측면에서 GDP와 같은 분기별 자료에 비해 월별 자료가 유리하기 때문에 월별 자료를 사용한다. 예를 들어, 현재 시점에 가장 최근 자료가 2021년 5월말에 공표된 자료이기 때문에 4월과 5월의 평균치를 2021년 2분기 자료로 사용한다. 또한 본 연구의 주된 목적은 향후 1년 내지 2년 이후의 물가상승률 예측이고 시계열 예측에 있어 상대적으로 잡음이 많은 월별 자료보다 분기별 자료가 중기 및 장기예측 정확도를 높이는데 유용하기 때문에 월별 자료를 분기별로 변환하여 사용한다.

추정과 예측에 사용되는 자료에 대한 설명과 출처는 Table 3에서 볼 수 있다. 각 거시변수를 예측변수 집합에 포함시킨 이유는 다음과 같다. 우선 VAR 모형을 이용한 조병수·이종웅·권인하(2021)의 최근 연구에서 우리나라 주택가격과 가계부채가 물가상승률에 미치는 영향이 통계적으로 유의함을 보고하였기에 주택가격지수와 주택담보대출 금리를 예측변수로 고려한다. 가계부채를 포함한 경제 전반의 유동성 변동은 M2, 실물경기 변동은 산업생산지수와 경기선행지수로 측

〈Table 3〉 List of Variables An asterisk(*) indicates that the variable is used for the SS-VAR model estimation.

	Abbreviation	transf.	Source
CPI*	CPI	YoY growth	Bank of Korea
Inflation expectation survey	IE	Level	Bank of Korea
Oil price index*	OP	YoY growth	OECD
Term spread (=10Yr - 1Yr)	Spread	Level	Bank of Korea
US CPI	USP	YoY growth	St. Louis Fed
M2*	M2	YoY growth	Bank of Korea
Industrial production index*	IP	YoY growth	Bank of Korea
House price index	HP	YoY growth	Bank of Korea
KRW/USD exchange rate	EXR	YoY growth	Bank of Korea
Mortgage rate*	Mort	Level	Bank of Korea
US 10-year bond yield	USR	Level	Bank of Korea
Leading business cycle indicator	LI	Level	Bank of Korea

정한다. 민간의 인플레이션 기대 변화는 경제주체별 가격결정에 대한 의사결정에 반영되어 실제 인플레이션 변동을 야기할 수 있으므로 인플레이션 기대조사도 예측변수에 포함시킨다. 다음으로 이자율 장단기 스프레드는 채권시장의 물가상승률과 경기기대를 반영하며, 유가는 해외 경기 및 총공급 요인 변화에 대한 정보를 포함하기 때문에 예측변수로 고려될 수 있다. 최근 들어 강화된 글로벌 인플레이션 동조화 현상을 반영하여 미국 물가상승률을 예측변수로 추가하였으며(Kang and Shin, 2021), 미국장기금리는 미국경기기대에 대한 정보를 반영한다. SS-VAR 모형 추정에는 물가, 실물경기, 유동성, 해외요인 등을 대변하는 5개의 거시변수(CPI상승률, 유가, 주담대 금리, M2, 산업생산지수)를 택하여 사용한다.

2. 표본외 예측결과

Table 4은 모형별 표본외 예측결과를 나타낸 것이다.¹⁰⁾ 패널(a)은 VAR 모형의

10) 김스 샘플링의 크기는 2,000이며 모든 변수의 비효율성계수(inefficiency factor)는 2 내외에 불과하여 마코프 체인이 사후분포에 수렴한 것으로 판단된다.

예측시계별 RMSE이고, 패널(b)는 ADL과 AR 모형의 예측시계별 RMSE와 튜닝을 통해 최적 하이퍼-파라미터를 나타낸 것이다. 우선 패널(a)의 결과를 보면 LS-VAR 모형과 SS-VAR 모형 모두 예측시계가 커질수록 RMSE도 커지는 현상이 발견되어, 단기 예측력이 장기 예측력에 비해 월등히 우월하다는 것을 알 수 있다. 또한 점예측 결과가 시차에 크게 의존하지 않는다는 것도 특징적이다. 통상적으로 VAR 모형의 시차는 BIC(Bayesian Information Criteria)로 결정하는데, 미네소타 사전분포를 적용한 경우에는 비정보적 사전분포를 가정한 BIC 기준으로 시차를 선택할 수 없다. 특히 미네소타 사전분포를 사용하게되면 BIC는 시차를 과소선택한다는 문제가 있다. 따라서 본고는 깁스 샘플링을 통해 주변 우도

〈Table 4〉 Out-of-sample Forecasting Performance Comparison

This table reports the RMSEs of the competing models. Panel (a) presents the RMSEs of the large and small scale VAR models with four different lags. Panel (b) reports the RMSE and PPL of the best ADL and AR models along with the best hyper-parameters. $\ln PPL$ is log PPL, J is the lag, b_0 is the exponent of the prior mean of b_0 , and WS is the window size. Nor is the normalization method. Nor=1 and 2 indicate the Z-score and Minnesota type scaling, respectively. MW is the model weight based on the PPL.

(a) VAR models

H	Large Scale VAR				Small Scale VAR			
	$J=1$	$J=2$	$J=3$	$J=4$	$J=1$	$J=2$	$J=3$	$J=4$
1	0.581	0.562	0.609	0.371	0.531	0.599	0.555	0.563
2	0.661	0.650	0.786	0.669	0.591	0.592	0.595	0.610
3	0.741	0.742	0.766	1.386	0.668	0.669	0.736	0.741
4	0.868	0.914	0.728	1.449	0.746	0.761	0.806	0.802
5	0.874	0.957	1.101	0.978	0.887	0.912	1.025	0.893
6	1.034	0.988	1.594	0.982	1.036	1.090	1.059	1.042
7	1.131	1.133	1.080	1.194	1.181	1.153	1.135	1.123
8	1.402	1.276	1.345	1.792	1.291	1.324	1.371	1.297
9	1.508	1.367	1.448	2.249	1.373	1.320	1.380	1.333
10	1.386	1.534	1.459	1.631	1.411	1.517	1.469	1.440
11	1.551	1.472	1.648	1.472	1.672	1.577	1.571	1.620
12	1.968	1.851	2.027	2.034	1.718	1.778	1.641	1.672

(b) ADL and AR models

H	ADL							AR		
	RMSE	lnPPL	<i>J</i>	b0	WS	Nor	MW	RMSE	lnPPL	MW
1	0.595	-21.63	1	-8	32	2	0.59	0.642	-24.22	0.40
2	0.654	-20.88	2	-10	24	2	0.92	0.730	-24.77	0.08
3	0.768	-24.90	3	-10	32	1	0.90	0.788	-27.32	0.09
4	0.704	-27.66	2	-8	24	1	0.50	0.771	-26.89	0.24
5	0.652	-24.62	3	-8	32	1	0.73	0.741	-25.62	0.21
6	0.701	-24.90	1	-4	32	1	0.96	0.792	-27.88	0.03
7	0.732	-27.65	1	-6	32	1	0.82	0.823	-27.73	0.10
8	0.752	-26.91	3	-10	24	2	1.00	0.853	-27.52	0.00
9	0.771	-26.90	2	-8	32	1	0.76	0.815	-27.25	0.16
10	0.738	-25.72	2	-10	28	2	0.51	0.743	-26.22	0.37
11	0.708	-27.96	2	-10	28	2	0.28	0.707	-24.86	0.10
12	0.674	-24.35	3	-10	28	1	0.79	0.659	-24.38	0.12

(marginal likelihood)를 직접적으로 계산하였다.¹¹⁾ 계산 결과, LS-VAR은 최적 시차가 3, SS-VAR의 최적 시차는 4로 계산되었다. 한편 패널(b)에 있는 ADL과 AR 모형의 RMSE 결과와 비교하더라도 VAR 모형의 단기예측결과가 결코 나쁘지 않다는 것을 알 수 있다.¹²⁾


11) 주변우도의 구체적인 계산과정은 Dieppe, Legrand, and Roye (2016)을 참조하길 바란다.







12) 빈도주의 접근법을 사용한 최인·황승진(2012)은 점예측 결과를 대상으로 Diebold-Mariano 검정을 진행한다. 반면 본 연구는 베이지안 접근법에서 예측력 비교는 모형간 상대적인 PPL의 크기, 즉 각 모형에 대한 가중치로 이루어진다.

〈Figure 1〉

Out-of-sample Prediction: ADL

This figure plots the H-period-ahead out-of-sample forecasts generated from the best ADL model. The red solid line is the realized inflation rate, the blue dashed line is the posterior predictive mean, and dotted lines are 90% credibility intervals.












〈Figure 2〉

Out-of-sample Prediction: AR


This figure plots the H-period-ahead out-of-sample forecasts generated from the best AR model. The red solid line is the realized inflation rate, the blue dashed line is the posterior predictive mean, and dotted lines are 90% credibility intervals.











〈Figure 3〉 Out-of-sample Prediction: Small-scale VAR


This figure plots the H-period-ahead out-of-sample forecasts generated from the small scale VAR model. The red solid line is the realized inflation rate, the blue dashed line is the posterior predictive mean, and dotted lines are 90% credibility intervals.











〈Figure 4〉 Out-of-sample Prediction: Large-scale VAR

This figure plots the H-period-ahead out-of-sample forecasts generated from the large scale VAR model. The red solid line is the realized inflation rate, the blue dashed line is the posterior predictive mean, and dotted lines are 90% credibility intervals.





<Table 5>

Selected Variables: ADL models

This table presents the selected variables across the forecasting horizons. ADL(1st) and ADL(2nd) indicate the best and second best models, respectively, in terms of the RMSE. const. is the intercept term.

H	ADL(1st)	ADL(2nd)
1	const, CPI(-1), IP(-1), LI(-1)	const, CPI(-1)
2	const, CPI(-1),	const, CPI(-1)
3	const, CPI(-1),	const, CPI(-1)
4	const, IE(-1), EXR(-1), EXR(-2), USR(-2)	const, CPI(-1)
5	const, CPI(-1), HP(-2), USR(-2)	CPI(-1), IE(-1), OP(-1), Spread(-1), M2(-1), Mort(-1), LI(-1), IP(-2),
6	const, CPI(-1), IE(-1), OP(-1), M2(-1), IP(-1), EXR(-1), Mort(-1), USR(-1)	const, IE(-1), OP(-1), M2(-1), IP(-1), Mort(-1)
7	const, IE(-1), USP(-1), M2(-1), HP(-1), EXR(-1), Mort(-1), USR(-1)	const, IE(-1), OP(-1), M2(-1), IP(-1), Mort(-1), USR(-1), LI(-1)
8	const, CPI(-1), IP(-1), IE(-2), IE(-3)	IE(-1), OP(-1), EXR(-1), Mort(-1), IE(-2), Spread(-2), Mort(-2), LI(-2), IE(-3), USP(-3), EXR(-3), IP(-3)
9	const, CPI(-1)	const, OP(-1), IP(-1), LI(-1)
10	const, CPI(-1), USP(-1), M2(-1)	const, Spread(-1), EXR(-1)
11	const, CPI(-1)	const, CPI(-1)
12	const, CPI(-1), USP(-2)	const, CPI(-1)

그럼에도 분포예측 정확도 측면에서는 VAR 모형의 단기 예측력이 좋다고는 볼 수 없다. Figure 1-4는 ADL, AR, LS-VAR, SS-VAR의 표본외 예측결과를 예측시계 별로 나타낸 것이다. 1분기 예측에 대한 VAR 모형의 90% 신용구간 (credibility interval)의 폭이 거의 4%p인 반면, ADL와 AR 모형의 1분기 예측의 90% 신용구간 폭은 2%p정도에 불과하다는 것을 볼 수 있다. 따라서 VAR 모형들의 단기예측은 점추정 측면에서는 나쁘지 않지만 분포나 구간 예측 측면에서는 신뢰도가 대단히 낮다. VAR 모형은 규모와 무관하게 물가상승률 예측에는 ADL이나 AR 모형에 비해서 유용성이 현저하기 낮은 것으로 판단된다. 참고로 SS-VAR 모형의 경우 예측력이 종속변수의 구성에 민감할 가능성이 있다. 그러

나 실제로 변수 구성을 다양한 바뀔가며 추정하더라도 SS-VAR 모형의 평균적인 예측 정확도는 거의 개선되지 않았다.

한편 VAR 모형과 ADL 모형의 예측력 차이는 직접 예측 방법과 반복 예측 방법의 차이를 반영한 것일 수도 있다. 또한 ADL은 Sparsity를 통해 차원을 축소하는 접근법을 적용한 반면, VAR 모형에는 미네소타 사전분포를 통해 Shrinkage가 적용되었기 때문에 과도적합문제 해결방식의 차이로 인해서 예측력 차이가 발생했을 가능성도 있다.

다음으로 ADL과 AR 모형의 표본외 예측결과를 RMSE와 PPL 기준으로 비교해보면 대부분의 예측시계에서 AR 모형보다 ADL 모형이 우세하다는 것을 알 수 있다.¹³⁾ 이는 ADL 모형의 예측결과인 Figure 1와 나머지 모형들의 예측결과를 나타내는 Figure 2-4의 비교를 통해서도 확인할 수 있다. 특히 2021년 들어 급격한 물가상승률을 AR과 VAR 모형은 거의 예측하지 못한 반면에, ADL 모형은 여러 분기 이전부터 훨씬 정확하게 예측하였음을 볼 수 있다. 이 결과로부터 물가상승률 예측에는 물가상승률의 시차변수 외에 통계적으로 유의한 예측력을 가진 거시변수들이 존재하며, 예측시계 별로 예측력이 강한 정보변수를 선별하는 것이 예측력 향상에 대단히 중요하다는 사실을 알 수 있다.

ADL 모형 추정결과로부터 각 예측시계 별로 선택된 예측변수를 Table 5에 나타내었다. 이 표를 보면 예측시계에 따라서 주요한 정보변수가 상당히 다르다는 것이 드러난다. 이 결과는 물가상승률 예측에 있어 주요한 거시지표가 장기와 단기 예측별로 상이하다는 것을 의미한다. 특히 단기 예측에는 전기 물가상승률, 산업생산지수, 경기선행지수가 중요하고, 6분기 예측에는 인플레이션 기대, 유가, 통화량, 산업생산지수, 금리 등이 중요한 예측변수로 선택되었다. 장기예측에는 우리나라와 미국 물가상승률, 통화량, 인플레이션 기대 등이 주요 정보변수로 작용하였다.

Table 4을 보면 확장 회귀에 비해 롤링 회귀가 보다 정확한 표본외 예측력을 나타낸다. 우리나라는 2012년 전후로 평균 물가상승률의 하락하였으며 2020년 말까지 이러한 현상이 지속되었다. 롤링 회귀는 이러한 평균 물가상승률의 구조 변화를 반영하기 때문에 이를 반영하지 못하고 잠재적인 편의를 야기하는 확장 회귀에 비해 높은 예측력을 나타내는 것으로 판단된다.

튜닝 과정에서 설명한 바와 같이 RMSE를 기준으로 가장 예측력이 높은 두

13) 비록 표나 그림으로 보고하지는 않았지만 튜닝과정을 거치지 않으면 지나치게 많은 변수가 선택되거나 중요한 변수의 역할이 과소평가되어 RMSE가 1보다 커지는 경우가 빈번히 발생한다.

ADL 모형과 AR 모형 중 예측력이 가장 높은 모형의 예측분포를 조합하여 물가 상승률 예측분포를 추정한다. PPL의 상대적 크기를 각 모형의 가중치로 사용하여 예측 조합을 실시한다. 연구목적상 구간예측이 정확해야 하며 구간예측 정확도는 RMSE보다는 PPL로 측정하는 것이 바람직하기 때문이다. 즉, RMSE가 작다고 해서 PPL이 높은 것은 결코 아니며, 이는 RMSE는 PPL에 비해서 꼬리 예측정확도를 과소평가하는 성질이 있기 때문이다. Table 4에서 ADL 모형의 MW는 RMSE가 가장 작은 ADL 모형에 대한 가중치이고 AR 모형의 MW는 AR 모형에 대한 가중치를 나타낸 것이다. 1에서 두 MW값을 뺀 것이 두 번째로 좋은 ADL 모형에 대한 가중치에 해당한다. 대부분의 예측시계에서 전반적으로 ADL 모형의 가중치가 크다는 것을 알 수 있다. 따라서 ADL과 AR 모형의 표본외 예측결과 상으로 점예측과 분포예측의 정확도가 대체로 비례하는 것으로 보인다.

3. 실제 예측결과


Figure 5는 2021년 2분기 시점에서 향후 12분기 동안의 물가상승률의 사후예측분포를 나타낸 것이다. 굵은 파란 실선은 사후평균, 점선은 80% 신용구간, 얇은 실선은 95% 신용구간을 나타낸 것이다. 물가상승률 예측의 주요결과는 크게 두 가지로 요약할 수 있다. 첫째, 물가상승률이 2022년 하반기까지는 현재 비슷한 2% 내외의 수준을 유지할 것으로 보이며, 2023년 상반기부터는 1% 내외로 하락할 것으로 예측된다. 특히 22년 4분기는 3%를 상회할 가능성도 높게 나타났다. 따라서 최근의 물가상승률 상승은 일시적인 현상으로 추정되고 향후 2년 정도 현 수준 내외를 유지하다가 그 이후에는 1%대로 하락할 것으로 예상된다.

둘째, 신용구간 추정치를 보면 향후 물가상승률 불확실성이 상당하다. 예측시계에 따라 차이가 있고, 80% 신용구간의 폭이 2%p에 못 미치는 것을 고려하더라도, 2022년 4분기와 2023년 4분기는 3%p를 초과한다. 물가상승률 불확실성이 이렇게 높음에도 불구하고 물가상승률 불확실성을 과소평가하게 되면 여러 경제주체의 최적 의사결정에 비효율성을 야기할 수 있다. 예를 들어, 중앙은행이 물가상승률 불확실성을 과소평가하게 되면 자체 예측에 대한 과도한 신뢰성으로 인해 지나치게 적극적인 금리 및 유동성 정책을 펴게 되고, 확률적으로 물가안정 목표제 달성에 실패할 가능성이 높아진다. 채권시장 참가자의 경우, 물가상승률 불확실성을 과소평가하게 되면 인플레이션 위험 프리미엄도 과소평가된다. 따라서 국채의 가치가 과대평가되어 결국 채권투자에 손실이 발생하게 된다.

앞서 밝힌 바와 같이 본고는 실제 예측분포 생성 시 모형 불확실성을 예측에 반영하고자 ADL 모형 중 표본외 예측력이 가장 좋은 두 모형과 AR 모형 중 표본외 예측력이 가장 우수한 모형을 상대적인 분포예측력을 기준으로 예측조합하였다. 하지만 튜닝과 실제 예측 간 일관성을 위해서는 개별 모형의 예측력과 예측조합의 예측력을 비교하여 예측조합 여부에 대한 튜닝을 실시해야 한다. 실제로 이를 적용하기에는 예측조합의 수가 너무 많아서 계산비용이 과다해지는 문제가 있다. 이 때문에 본 연구는 임의의 예측조합결과를 제시하였는데, 그럼에도 예측과정의 일관성에 문제가 있기 때문에 Figure 6에 모든 모형 중 가장 표본외 예측력이 우수한 모형(즉, ADL(1st))의 실제 예측결과를 추가로 제시한다. 실제 예측결과를 살펴보면, 예측조합과 ADL(1st)의 전반적인 예측분포는 유사하고, 다만 예측분포의 꼬리에 미세한 차이가 발생하는데, 두 예측결과 중 어떤 결과를 채택할지는 실제 경제적 의사결정 주체의 선택에 해당한다. 참고로 Figure 7은 AR 모형의 예측결과인데 지속적인 하향추세를 나타낸다는 측면에서 예측조합의 결과와 유사한 면이 있다.


〈Figure 5〉 Posterior Predictive Distribution: Forecast Combination

This figure plots the H-quarter-ahead posterior predictive distributions for $h=1,2,\dots$, and 12. The blue solid line is the posterior mean, the black dashed and solid lines are 80% and 95% credibility intervals, respectively.




〈Figure 6〉 Posterior Predictive Distribution: ADL(1st)

This figure plots the H-quarter-ahead posterior predictive distributions for $h=1,2,\dots$, and 12. The blue solid line is the posterior mean, the black dashed and solid lines are 80% and 95% credibility intervals, respectively.



〈Figure 7〉 Posterior Predictive Distribution: AR model


This figure plots the H-quarter-ahead posterior predictive distributions for $H=1,2,\dots$, and 12. The blue solid line is the posterior mean, the black dashed and solid lines are 80% and 95% credibility intervals, respectively.



〈Figure 8〉

Medium-term Inflation Forecast

This figure plots the posterior predictive distribution of the average inflation rate over the period, 2023:Q3 to 2024:Q2.



우리나라 물가안정목표제는 중기 시계로 2%이다. 하지만 ‘중기’라는 개념이 모호하고 한국은행이 기관 홈페이지나 발간자료에서 구체적인 기간을 명시하지 않는다. 그래서 통화정책 파급시차 등을 고려하여 Figure 6의 결과로부터 임의로 현재 시점에서 2년 후 1년간(2022년 3분기-2023년 2분기) 평균 물가상승률의 사후분포를 산출하였다. Figure 8이 중기 시계 물가상승률의 사후분포를 나타낸 것이다. 사후 평균은 0.999%이고 90% 신용구간은 [0.253%, 1.769%]이다. 한국은행이 설정한 목표물가상승률이 2%이기 때문에 중기 시계에서 실제 물가상승률은 목표 물가상승률을 하회할 확률이 95%에 달한다. 예측분포에 대한 해석 시 주의할 점은 본고의 예측모형은 축약식이기 때문에 물가상승률 예측분포 추정치는 앞으로 한국은행이 경기나 물가에 대해서 과거와 유사한 통화정책적 대응을 한다는 조건을 반영한다는 것이다. 또한 공급망 충격과 같이 과거에 비해 중요도가 높아진 외생적 변화가 예측정보에 충분히 반영되지 않았다는 점도 추정결과 해석 시 주의할 필요가 있다.

IV. 결론 및 정책적 시사점

1. 요약

본 연구는 네 개의 물가상승률 예측모형을 설정하고 직접예측과 반복예측 방법을 표본외 예측을 통해 비교하고, 모형선택결과를 바탕으로 실제 우리나라 물가상승률 예측치와 불확실성을 수치화하였다. 모형선택결과, 베이지안 변수선택기법이 적용된 ADL 모형과 AR 모형으로 직접예측하는 것이 VAR 모형으로 반복예측하는 것보다 우월한 것으로 나타났다. 특히 베이지안 변수선택기법 적용 시 광범위하고 엄밀한 튜닝과정을 거쳤는데, 예측시계측로 하이퍼-파라미터와 시차 및 롤링 윈도우 크기를 최적화하는 것이 예측력 향상에 결정적임을 발견하였다.

선택된 모형을 이용하여 향후 물가상승률의 예측분포를 도출한 결과, 앞으로 2년간은 현재 수준인 2% 내외를 유지할 것으로 보이며, 그 이후에는 점차 1% 내외로 하락할 것으로 예측된다. 하지만 앞으로 자료가 매월 지속적으로 누적되면서 예측분포가 업데이트되면 물가상승률 예측값이 수정될 가능성도 적지 않다는 점을 강조하고자 한다. 특히 만약 물가상승률 평균에 새로운 구조변화가 발생하고 이에 대한 통계적 유의성이 강화될수록 물가상승률의 예측치와 불확실성 크기가 달라질 것이다.

2. 정책적 시사점

거듭 강조컨대 본고는 최근 향후 물가경로에 대한 관심이 높아지고, 불확실성도 커지고 있다는 점을 고려하여 물가예측을 실시하였다. 예측 결과 물가상승률이 2022년 하반기까지는 현재와 비슷한 2% 내외의 수준을 유지할 것으로 보이며, 2023년 상반기부터는 1%대로 하락할 것으로 추정된다. 이는 최근의 상대적으로 높은 물가가 당분간 지속될 가능성이 높다는 점을 시사한다. 글로벌 금융위기 이후 성장률이 낮아지면서 물가가 1%대로 내려왔다는 사실을 고려할 때 이러한 물가경로는 저금리 여건에 익숙한 경제 주체들에게 적지 않은 충격이 될 수 있을 것이다. 물가가 높아지면서 금리도 상승할 경우 가계부채가 높아진 상황에서는 민간의 원리금 상황이 커질 수 있고, 자산규모가 큰 고소득층보다 자산이 적은 저소득층의 부담이 상대적으로 높아질 수 있다. 더구나 소득이 물가상승률

에 미치지 못할 경우 이는 소비의 직접적인 제약요인으로 작용할 수 있다는 점에 유의할 필요가 있다. 대외적으로는 물가 변화에 따른 금리변동이 내외금리차를 통해 환율에도 영향을 미칠 수 있다. 내외금리차가 글로벌 자본이동에 영향을 미치고 환율 경로를 통해 경상수지의 변화를 초래한다는 사실은 다양한 실증분석을 통해 뒷받침되고 있다. 소규모 개방경제하에서 수출입의 영향이 적지 않은 우리 여건에서 이러한 대외적 변화에도 주목해야 한다. 경제주체의 기대나 심리 측면에서도 향후 물가 흐름의 변화는 중요한 의미를 갖는다. 민간의 기대보다 급격한 물가의 변화는 미래에 대한 불확실성을 높이며, 경제활동의 심리적 위축을 초래할 수 있다. 향후 경제여건에 대한 불확실성일 줄이고 적절한 기대형성을 유도하기 위해서는 물가 변화에 대한 시의적절한 정보제공이 필요하다. 이러한 점을 고려하여 저자들은 본고의 물가예측치를 정기적으로 인터넷에 공개함으로써 민간의 기대형성에 기여하고자 한다. 정부 등도 민간이 높아지는 물가 환경에 적응할 수 있도록 다양한 정책적 노력을 기울일 필요가 있을 것이다.

3. 한계 및 추가 연구방향

본 연구의 목적과 분석방법 상에 여러 한계가 존재한다. 본 연구의 주제는 정확한 장단기 물가상승률 예측에 국한되고 이를 위해 구조모형이 아닌 축약형 모형을 사용한다. 이로 인해 특정 예측변수가 중요한 변수로 선택되더라도 구체적으로 어떠한 경로로 물가상승률에 영향을 미치는지를 설명할 수 없다는 한계를 지닌다. 게다가 각 변수의 선택 여부는 전적으로 통계적 기준에 의해서 결정되기 때문에 경제학적 또는 구조적인 근거를 파악할 수 없다. 또한 각 설명변수는 사전에 실현된(pre-determined) 내생변수이므로 각 설명변수가 특정 구조충격을 대변하지 않는다. 예를 들어, 산업생산지수에는 이미 국내와 해외 실물경기 그리고 유동성이나 재정 통화정책 충격이 모두 내재하기 때문에, 산업생산지수가 중요한 정보변수로 선택되었다 하더라도 이를 국내경기 효과라고만 해석할 수는 없다. 축약형 모형의 특성상 물가상승률과 인플레이션 기대, 금리와 같은 거시변수들 간 동태적 상호관계를 구조적으로 분석하는 것도 어렵다. 또한 GDP와 같은 분기자료를 예측변수로 추가 고려할 수 있는 혼합주기 모형도 고려해 볼 만 할 것이다.

한편 본 연구의 추정방법은 베이지안 머신러닝기법에 속한다. 최근 Marcelo, Gabriel, Vasconcelos, Veiga and Zilberman (2021)은 랜덤 포레스트(Random Forest), Bagging, LASSO, adaptive LASSO, 주성분 분석, 베이지안 VAR, Ridge,

Elastic net 등 다양한 머신러닝기법의 미국 인플레이션 예측력을 비교하였다, 1개월부터 6개월 이후 예측 중 대부분의 예측시계에서 랜덤 포레스트가 RMSE를 기준으로 여타 기법에 비해 우월하다는 결과를 보고하였다. 비록 이 논문에서 채택한 머신러닝기법이 분포나 구간예측에는 유용하지 않으니 전통적인 머신러닝 기법과 베이지안 머신러닝 기법을 점 예측을 기준으로 비교해보는 것도 충분히 시도해 볼 만한 연구로 사료된다. 한편 최근 Choi and Jeong (2020)는 차분된 자료에 기반한 전통적인 시계열분석과 비교하여 수준 자료를 이용하면 예측력이 향상될 수 있음을 보였다. 이러한 연구결과를 반영하여 물가 수준 자료를 이용한 예측을 실시하고 기존 물가상승률에 기반한 예측결과와 비교하는 연구도 추후 이루어질 필요가 있다.

마지막으로 장기 예측에 있어 평균 물가상승률의 구조변화 가능성을 고려하는 것이 대단히 중요하지만 본 연구는 마코프-스위칭이나 시변계수 등 구조변화과정을 명시적으로 모형 내에 도입하지 않는다는 한계도 있다. 이는 기본적으로 구조변화 여부나 구조변화 발생 시점을 예측함으로써 발생하는 비효율성이 구조변화를 고려함으로써 제거되는 잠재적인 편의보다 일반적으로 크기 때문이다. 그럼에도 앞으로 보다 많은 시계열 자료가 축적되면 구조변화 도입의 편익이 명확해질 것으로 판단된다. 향후 지속적인 후속 연구를 통해 혼합주기 모형을 포함하여 앞서 언급한 여러 한계점을 검증하고 극복하는 과정에서 우리나라 물가상승률의 예측정확도를 개선할 수 있을 것으로 기대한다.

〈참고문헌〉

- 감형규, 신용재, 박형중(2007), "한국 주식시장의 산업별 비대칭적 주가변동성에 관한 연구," 기업경영연구, 제14권 제1호, 한국기업경영학회, 99-112.
- 강규호(2018), "베이지안 머신 러닝을 이용한 은행권 주택담보대출 예측," 금융안정연구, 제19권 제1호, 예금보험공사, 99-129.
- 김현학(2015), "예측조합 및 밀도함수에 의한 소비자물가 상승률 전망," 경제분석, 제21권 제3호, 한국은행, 103-136.
- 조병수, 이종웅, 권인하(2021), "주택가격 변동이 실물·물가에 미치는 영향의 비대칭성 분석," BOK 이슈노트, 제2021-17호, 한국은행.
- 최인, 황승진(2012), "한국의 인플레이션 예측," 응용경제, 제14권 제3호, 한국응용경제학회, 133-168.

- Blanchard, O. (2021), "In Defense of Concerns over the \$1.9 Trillion Relief Plan," *PIIE Realtime Economic Issues Watch*.
- Choi, In. and Hanbat Jeong (2020), "Differencing versus Non-Differencing in Factor-based Forecasting," *Journal of Applied Econometrics*, Vol. 35(6), pp. 728-750.
- Dieppe, Alistair, Romain Legrand, and Bjorn van Roye (2016), "The Bear Toolbox," European Central Bank Working Paper, No. 1934.
- Fulton, Chad, and Kirstin Hubrich (2021), "Forecasting US inflation in real time," Finance and Economics Discussion Series, 2021-014.
- Giannone, Domenico, Michele Lenza, and Giorgio E. Primiceri (2015), "Prior selection for vector autoregressions," *Review of Economics and Statistics*, Vol. 97(2), pp. 436-451.
- IMF (2020), *Annual Report on Exchange Arrangements and Exchange Restrictions 2019*, International Monetary Fund.
- Kang, Kyu Ho and Inseok Shin (2021), "Has International CPI Inflation Comovement Strengthened since the Global Financial Crisis?" *Macroeconomic Dynamics*, pp. 1-30.
- Kim, S., N. Shephard, and S. Chib (1998), "Stochastic volatility: Likelihood inference and comparison with arch models," *Review of Economic Studies*, Vol. 65, pp. 361-393.
- Kim, Young Min and Seojin Lee (2020), "Exchange rate predictability: A variable selection perspective," *International Review of Economics & Finance*, Vol. 70, 117-134.
- Korobilis, Dimitris (2013), "VAR Forecasting using bayesian variable selection," *Journal of Applied Econometrics*, Vol. 28(2), pp. 204-230.
- Little, J. and T. Romano (2009), "Inflation Targeting—Central Bank Practice Overseas," *Federal Reserve Bank of Boston Public Policy Briefs*, No. 08-1.
- Marcelo C. Medeiros, Gabriel F. R. Vasconcelos, Álvaro Veiga & Eduardo Zilberman (2021), "Forecasting Inflation in a Data-Rich Environment: The Benefits of Machine Learning Methods," *Journal of Business & Economic Statistics*, Vol. 39(1), pp. 98-119.
- Roger, S. and M. Stone (2005), "On target? The International Experience with Achieving Inflation Targets," IMF Working Paper, WP/05/163.
- Stock, James H., and Mark W. Watson (1999), "Forecasting inflation," *Journal of Monetary Economics*, Vol. 44(2), pp. 293—335.
- Summers, Lawrence H. (2021), "My column on the stimulus sparked a lot of questions. Here are my answers," Washington Post, February 7.
- Yang, A., Xiang, J., Shu, L. et al. (2018), "Sparse Bayesian Variable Selection with Correlation Prior for Forecasting Macroeconomic Variable using Highly Correlated Predictors," *Computational Economics*, Vol. 51, pp. 323-338.
- Wright, Jonathan H. (2009), "Forecasting US inflation by Bayesian model averaging," *Journal of Forecasting*, Vol. 28(2), pp. 131-144.

부록 A. ADL 모형 사후 샘플링 알고리즘

본고에서는 파라미터 $\beta, \sigma^2, b_0, b_1, p$ 그리고 각각 k 번째 설명변수의 중요도에 해당하는 γ_k 들의 행렬인 $\Gamma = (\gamma_0, \gamma_{1,1}, \gamma_{1,2}, \dots, \gamma_{K+1,J-1}, \gamma_{K+1,J})$ 의 사후분포를 깁스 샘플링을 사용하여 도출하였다.

A1. (σ^2, β) 샘플링

본문에서와 같이 식 (2)를 $Y = X\beta + e$ 로 표현할 때, β 의 완전 조건부 분포는 다음과 같이 정규분포를 따른다.

$$\begin{aligned}\beta \mid Y, \theta_{-\beta}, \Gamma &\sim N(\bar{\beta}, \bar{B}) \\ \bar{B} &= (\sigma^2 X'X + B_0^{-1})^{-1} \\ \bar{\beta} &= \sigma^{-2} \bar{B} X' Y\end{aligned}$$

$\theta_{-\beta}$ 는 β 를 제외한 다른 파라미터 집합이며 β 의 사전 분산-공분산 행렬 B_0 은 식 (3)을 따라 다음과 같이 나타낼 수 있다.

$$B_0 = \text{diag}[(1 - \Gamma) \times b_0 + \Gamma \times b_1]$$

B_0 는 $\gamma_{k,j}$ 값에 따라 결정되는 $(K+1) \times J+1$ 대각행렬이며 반복시행 초기에는 γ 의 초기값이 모두 1로 지정되어 모든 값이 b_1 인 대각행렬이지만, 이후 Γ 가 샘플링되어 새롭게 값이 저장되면 반복시행의 횟수가 늘어날수록 주어진 X,Y자료를 반영한 사전 분산-공분산 행렬이 생성된다. σ^2 는 앞서 추출한 β 를 반영한 역감마분포를 완전조건부분포로하여 다음과 같은 역감마분포에서 샘플링된다.

$$\sigma^2 \mid Y, \beta \sim IG((\alpha_0 + T)/2, (\delta_0 + (Y - X\beta)'(Y - X\beta))/2)$$

A2. Γ 샘플링

다음으로 γ_k 의 완전조건부 확률인 $\pi[\gamma_k \mid Y, \beta_k, p, b_0, b_1]$ 는 독립인 항을 제외하면 $\pi(\beta_k \mid b_0, b_1, \gamma_k) \pi(\gamma_k \mid p)$ 에 비례하는데, γ_k 은 0 또는 1의 값을 가지므로 γ_k 가 1의 값을 가질 완전 조건부 확률을 베이즈룰에 따라 구하면 다음과 같다.

$$\begin{aligned}\Pr(\gamma_{k,j} = 1 \mid \beta_{k,j}, b_0, b_1) &= \frac{\pi(\beta_{k,j} \mid b_0, b_1, \gamma_{k,j} = 1) \Pr(\gamma_{k,j} = 1 \mid p)}{\pi(\beta_{k,j} \mid b_0, b_1, \gamma_{k,j} = 1) \Pr(\gamma_{k,j} = 1 \mid p) + \pi(\beta_{k,j} \mid b_0, b_1, \gamma_{k,j} = 0) \Pr(\gamma_{k,j} = 0 \mid p)} \\ &= \frac{p \times N(\beta_{k,j} \mid 0, b_1)}{p \times N(\beta_{k,j} \mid 0, b_1) + (1-p) \times N(\beta_{k,j} \mid 0, b_0)}\end{aligned}$$

따라서 γ_k 는 균일분포에서 임의로 추출한 값이 $\Pr(\gamma_k = 1 \mid \beta_k, b_0, b_1)$ 보다 작으면 1을, $\Pr(\gamma_k = 1 \mid \beta_k, b_0, b_1)$ 보다 크면 0을 지정하여 샘플링할 수 있다. 이 과정에서 앞서 설명한 것과 같이, 주어진 β_k 가 0에 가깝다면 분산이 b_0 를 따르는 확률 분포상의 밀도가 분산이 b_1 를 따르는 확률 분포상의 밀도보다 크므로 $\Pr(\gamma_k = 1 \mid \beta_k, b_0, b_1)$ 이 0에 가깝고 설명변수가 중요하다면 $N(\beta_k \mid 0, b_1)$ 가 더 큰 값을 가져, 사후확률 $\Pr(\gamma_k = 1 \mid \beta_k, b_0, b_1)$ 은 1에 가까운 값을 가진다. 주어진 사후확률에 의해 균등분포를 사용하여 $\gamma_{k,j}$ 를 샘플링할 수 있으며, $\gamma_{k,j}$ 의 사후평균을 (k, j) 번째 설명변수의 중요도라고 칭한다.

A3. (b_0, b_1) 샘플링

$\beta_{\Gamma=1}$ 는 $\gamma_{k,j}$ 가 1에 해당하는 모든 계수들의 집합이며 K_1 이 $\beta_{\Gamma=1}$ 원소의 개수를 나타내고, K_0 가 그렇지 않은 계수들의 수를 나타낸다고 하자. $\beta_{\Gamma=1}$ 는 정규분포 $\beta_{\Gamma=1} \mid b_1 \sim N(0, b_1)$ 를 따르고, b_1 의 사전분포가 역감마분포를 따르는 $\beta_{\Gamma=1}$ 의 분산이므로 b_1 의 완전조건부분포는 다음과 같으며 b_0 의 완전조건부분포 역시 동일하게 도출할 수 있다.

$$\begin{aligned}b_1 \mid \beta_{\Gamma=1} &\sim IG((\alpha_{01} + K_1)/2, (\delta_{01} + \beta'_{\Gamma=1} \beta_{\Gamma=1})/2) \\ b_0 \mid \beta_{\Gamma=0} &\sim IG((\alpha_{00} + K_0)/2, (\delta_{00} + \beta'_{\Gamma=0} \beta_{\Gamma=0})/2)\end{aligned}$$

A4. p 샘플링

p 의 완전조건부밀도는 우도와 사전 밀도의 곱에 비례하는데, 이 때 p 와 독립인 항들을 제외하면 p 의 완전조건부밀도는 다음과 같다.

$$\begin{aligned}\pi(\parallel t Y, \beta, \Gamma, b_0, b_1, \sigma^2) &\propto \pi(p) \pi(\Gamma \mid p) \\ &= \pi(\gamma_1, \gamma_2, \dots, \gamma_K \mid p) \pi(p) \\ &= p^{K_1} (1-p)^{K_0} \times p^{\alpha_0-1} (1-p)^{c_0-1}\end{aligned}$$

위의 식의 결과는 다시 $p^{a_0+K_1-1}(1-p)^{c_0+K_0-1}$ 로 나타낼 수 있는데, 이는 베타분포의 밀도와 같다. 따라서 p 의 완전조건부 분포는 다음과 같이 나타낼 수 있다.

$$p \mid \Gamma \sim \beta(a_0 + K_1, c_0 + K_0)$$

부록 B. Tuning Algorithm

```

for Normalization = Z_score, Minnesota type % Normalizing regressors
  for  $J = 1, 2, 3$  % Lag
    for  $\delta_{00}/\alpha_{00} = 10^{-4}, 10^{-6}, 10^{-8}, 10^{-10}$  % Shrinkage parameter
      if Rolling windows
        for Window size = 20, 24, 28, 32
          for OSS_j = 1, 2, ..., 20
            (i) parameter sampling
            (ii) out-of-sample forecasting
          end
          (i) RMSE computation
          (ii) PPL computation
        end
      end
      if Expanding regression
        for OSS_j = 1, 2, ..., 20
          (i) parameter sampling
          (ii) out-of-sample forecasting
        end
        (i) RMSE computation
        (ii) PPL computation
      end
    end
  end
end

```

Forecasting Korean CPI Inflation

Kyu Ho Kang*, Jungsung Kim**, Serim Shin***

The outlook for Korea's consumer price inflation rate has a profound impact not only on the Bank of Korea's operation of the inflation target system but also on the overall economy, including the bond market and private consumption and investment. This study presents the prediction results of consumer price inflation in Korea for the next three years. To this end, first, model selection is performed based on the out-of-sample predictive power of autoregressive distributed lag (ADL) models, AR models, small-scale vector autoregressive (VAR) models, and large-scale VAR models. Since there are many potential predictors of inflation, a Bayesian variable selection technique was introduced for 12 macro variables, and a precise tuning process was performed to improve predictive power. In the case of the VAR model, the Minnesota prior distribution was applied to solve the dimensional curse problem. Looking at the results of long-term and short-term out-of-sample predictions for the last five years, the ADL model was generally superior to other competing models in both point and distribution prediction. As a result of forecasting through the combination of predictions from the above models, the inflation rate is expected to maintain the current level of around 2% until the second half of 2022, and is expected to drop to around 1% from the first half of 2023.

JEL Classification Number: G12, C11, E43

Keywords: Out-of-sample forecasting, Inflation targeting, business cycle, variable selection

* First and Corresponding author. Department of Economics, Korea University, Seoul, 02841, South Korea (E-mail: kyuho@korea.ac.kr, Tel: 02-3290-5132)

** Research Department, Bank of Korea, Seoul, 04514, South Korea
(E-mail: jskim77@bok.or.kr, Tel: 02-759-4114)

*** Department of Economics, Korea University, Seoul, 02841, South Korea
(E-mail: shinserim2@korea.ac.kr, Tel: 02-3290-2200)

The views expressed in this paper are those of the authors and do not necessarily reflect the position of the Bank of Korea. Kyu Ho Kang acknowledges the financial support from the Korea University (K2001811)

Received: 11 August 2021, Received in revised form: 6 September 2021, Accepted: 30 November 2021